# Desenho da Solução - ACME Risk Analysis

### Visão Geral

Este documento apresenta o desenho detalhado da solução de análise de risco de transações financeiras, com foco em **resiliência**, **escalabilidade** e **alto desempenho**. A arquitetura foi projetada para suportar milhares de transações por segundo (TPS) mantendo alta disponibilidade e tolerância a falhas.

# Arquitetura de Alto Nível

### **Componentes Principais**

#### 1. Load Balancer / API Gateway

- Tecnologias: NGINX, AWS Application Load Balancer, Kong API Gateway
- Responsabilidades:
- Distribuição inteligente de carga entre instâncias
- Rate limiting para proteção contra DDoS
- SSL termination e segurança de rede
- Health checks automáticos
- Roteamento baseado em path/header

### 2. Risk Analysis Service (Múltiplas Instâncias)

- Porta: 8080
- Padrão: Stateless, horizontalmente escalável
- Responsabilidades:
- Orquestração do fluxo de análise de risco
- Geração de tokens JWT para comunicação interna

- Implementação de Circuit Breaker pattern
- Agregação de resultados dos serviços downstream

#### 3. Lists Service (Múltiplas Instâncias)

• Porta: 8081

• Padrão: Stateless com cache em memória

• Responsabilidades:

- Gerenciamento de listas permissivas e restritivas
- Cache inteligente para otimização de performance
- Validação de CPF, IP e Device ID

#### 4. Decision Engine Service (Múltiplas Instâncias)

• Porta: 8082

• Padrão: Stateless com cache de regras

• Responsabilidades:

- Execução do motor de regras de negócio
- Cálculo de score de risco.
- Cache de regras para performance otimizada
- CRUD de regras dinâmicas

# Estratégias de Resiliência

#### 1. Circuit Breaker Pattern

• Implementação: Hystrix ou Resilience4j

• Configuração:

• Timeout: 5 segundos

• Retry: 3 tentativas com backoff exponencial

• Fallback: Negar transação por segurança

• Benefícios: Previne cascata de falhas entre serviços

### 2. Health Checks e Auto-Recovery

- Endpoints: /health em todos os serviços
- Monitoramento: Verificação a cada 30 segundos
- Ação: Remoção automática de instâncias não saudáveis do load balancer

#### 3. Graceful Degradation

- Cenário: Falha do Lists Service
- **Comportamento**: Continua análise sem verificação de listas (score mais conservador)
- Cenário: Falha do Decision Engine Service
- Comportamento: Aplica regras básicas hardcoded ou nega por segurança

### 4. Multi-AZ Deployment

- **Distribuição**: Instâncias em múltiplas zonas de disponibilidade
- Benefício: Tolerância a falhas de infraestrutura
- Replicação: Database com master/slave em AZs diferentes

# Estratégias de Escalabilidade

#### 1. Escalabilidade Horizontal

- Auto-scaling: Baseado em CPU, memória e latência
- **Kubernetes**: Horizontal Pod Autoscaler (HPA)
- Métricas de Trigger:
- CPU > 70%
- Latência P95 > 100ms
- Queue depth > 1000 mensagens

#### 2. Stateless Design

- Princípio: Nenhum estado mantido nos serviços
- Benefício: Instâncias podem ser adicionadas/removidas dinamicamente
- Session Storage: Redis para dados de sessão se necessário

### 3. Database Scaling

- Read Replicas: Para consultas de listas e regras
- Connection Pooling: HikariCP com configuração otimizada
- Sharding: Particionamento por região ou tipo de transação

#### 4. Cache Distribuído

- Tecnologia: Redis Cluster
- Estratégia: Cache-aside pattern
- TTL: Configurável por tipo de dado
- Invalidação: Event-driven via message queue

# Estratégias de Performance

### 1. Targets de Performance

- TPS: 10,000+ transações por segundo
- Latência: < 100ms P95 end-to-end
- Disponibilidade: 99.9% (8.76 horas de downtime/ano)
- RTO: < 5 minutos (Recovery Time Objective)
- **RPO**: < 1 minuto (Recovery Point Objective)

## 2. Otimizações de Comunicação

- HTTP/2: Para reduzir latência de rede
- Connection Pooling: Reutilização de conexões HTTP

- Compression: GZIP para payloads grandes
- **Keep-Alive**: Conexões persistentes

#### 3. Processamento Assíncrono

- Message Queue: Kafka ou RabbitMQ
- Casos de Uso:
- Auditoria de transações
- Atualização de métricas
- Notificações
- Benefícios: Desacoplamento e melhor throughput

### 4. Cache Strategy

- **L1 Cache**: Cache local em cada instância (Caffeine)
- L2 Cache: Cache distribuído (Redis)
- Cache Warming: Pré-carregamento de dados críticos
- Cache Hierarchy: Dados mais acessados em cache mais rápido

## Monitoramento e Observabilidade

## 1. Métricas (Prometheus + Grafana)

- Business Metrics:
- Taxa de aprovação/negação
- Distribuição de scores
- Volume de transações por tipo
- Technical Metrics:
- Latência por endpoint
- Taxa de erro por serviço
- Utilização de recursos

### 2. Logging (ELK Stack)

• Structured Logging: JSON format

• Correlation ID: Rastreamento de requisições

• Log Levels: Configuráveis por ambiente

• Retention: 30 dias para produção

### 3. Distributed Tracing (Jaeger)

• Trace Sampling: 1% em produção, 100% em desenvolvimento

• Span Tags: Informações de contexto de negócio

• Performance Analysis: Identificação de gargalos

## 4. Alerting

• Canais: Slack, PagerDuty, Email

• Alertas Críticos:

- Latência > 200ms por 5 minutos
- Taxa de erro > 1% por 2 minutos
- Disponibilidade < 99% por 1 minuto

## Segurança

## 1. Autenticação JWT

• Algoritmo: HS256 (desenvolvimento) / RS256 (produção)

• Expiração: 1 hora

• **Refresh**: Automático via interceptors

• Validação: Em todos os endpoints protegidos

## 2. Network Security

• TLS 1.3: Para todas as comunicações

- VPC: Isolamento de rede
- **Security Groups**: Acesso restrito por porta/protocolo
- WAF: Proteção contra ataques web

#### 3. Data Protection

- Encryption at Rest: Database e cache
- Encryption in Transit: TLS para todas as comunicações
- PII Masking: Logs não expõem dados sensíveis
- **GDPR Compliance**: Direito ao esquecimento

## **Disaster Recovery**

#### 1. Backup Strategy

- Database: Backup automático a cada 6 horas
- Configuration: Versionamento no Git
- Secrets: Backup seguro em vault
- Retention: 30 dias para backups

### 2. Recovery Procedures

- RTO Target: < 5 minutos
- RPO Target: < 1 minuto
- Automated Failover: Para componentes críticos
- Manual Procedures: Documentados e testados

### 3. Testing

- Chaos Engineering: Testes de falha regulares
- DR Drills: Simulação de desastres mensalmente
- Load Testing: Validação de capacidade

• **Security Testing**: Penetration tests trimestrais

# Considerações de Implementação

## 1. Tecnologias Recomendadas

- Container Orchestration: Kubernetes
- Service Mesh: Istio (para comunicação avançada)
- CI/CD: GitLab CI ou GitHub Actions
- Infrastructure as Code: Terraform

#### 2. Ambientes

- **Development**: Single instance, H2 database
- Staging: Configuração similar à produção
- Production: Full HA setup conforme desenho

### 3. Migration Strategy

- Blue-Green Deployment: Para atualizações sem downtime
- Feature Flags: Para rollout gradual de funcionalidades
- **Database Migrations**: Versionadas e reversíveis

## Conclusão

Este desenho de solução foi projetado para atender aos requisitos de:

- Alto Volume (TPS): Arquitetura horizontalmente escalável suporta 10,000+ TPS
- Resiliência a Falhas: Circuit breakers, health checks e graceful degradation
- Escalabilidade: Auto-scaling, stateless design e cache distribuído
- Performance: Otimizações de rede, cache multi-layer e processamento assíncrono

A implementação atual (versão de desenvolvimento) serve como base sólida para evolução para esta arquitetura de produção, mantendo os princípios de arquitetura hexagonal e segurança JWT já implementados.

Desenvolvido por Igor Meira - <u>meira.igor@gmail.com</u>